

毕业论文（设计）检测系统
文本复制检测报告单 (全文标明引文)

No: BC202605271949022177432001

检测时间: 2026-05-27 19:49:02

篇名: 基于农业知识增强的小麦病害辅助诊断方法研究

作者: 闫起 (2210101030)

指导教师: 司海平 (教授)

检测机构: 河南农业大学

文件名: 基于农业知识增强的小麦病害辅助诊断方法研究.docx

检测系统: 毕业论文（设计）检测系统（毕业论文（设计）管理系统）

检测类型: 毕业论文设计

检测范围: 中国学术期刊网络出版总库
中国博士学位论文全文数据库/中国优秀硕士学位论文全文数据库
中国重要会议论文全文数据库
中国重要报纸全文数据库
中国专利全文数据库
图书资源
优先出版文献库
大学生论文联合比对库
互联网资源(包含贴吧等论坛资源)
英文数据库(涵盖期刊、博硕、会议的英文数据以及德国Springer、英国Taylor&Francis 期刊数据库等)
港澳台学术文献库
互联网文档资源
源代码库
CNKI大成编客-原创作品库

时间范围: 1900-01-01至2026-05-27

检测结果

去除本人文献复制比: 2.3%

跨语言检测结果: -

去除引用文献复制比: 1.8%

总文字复制比: 2.3%

单篇最大文字复制比: 1.7% (浅谈小麦常见病虫害防治技术)

重复字数:	[624]	总段落数:	[8]
总字数:	[27504]	疑似段落数:	[4]
单篇最大重复字数:	[465]	前部重合字数:	[0]
疑似段落最大重合字数:	[513]	后部重合字数:	[624]
疑似段落最小重合字数:	[32]		



文字复制部分	1.8%
引用部分	0.5%
无问题部分	97.7%

指标: ☐ 疑似剽窃观点 ☒ 疑似剽窃文字表述 ☐ 疑似整体剽窃 ☐ 过度引用

相似表格: 0 相似公式: 检测中 疑似文字的图片: 0

0% (0)	0% (0)	中英文摘要等 (总2637字)
0.7% (32)	0.7% (32)	1 引言 (总4380字)
1% (37)	1% (37)	2 相关技术 (总3736字)
17.2% (513)	17.2% (513)	3 数据来源与处理 (总2986字)
0% (0)	0% (0)	4 算法构建 (总6032字)



1. 中英文摘要等	总字数: 2637
相似文献列表	
去除本人文献复制比: 0%(0) 去除引用文献复制比: 0%(0) 文字复制比: 0%(0) 疑似剽窃观点: (0)	
原文内容	

本科生毕业论文（设计）
基于农业知识增强的小麦病害辅助诊断方法研究
Research on Auxiliary Diagnosis Method of Wheat Diseases Enhanced by Agricultural Knowledge
学院信息与管理科学学院
学生姓名闫起
学号 2210101030
专业计算机科学与技术
指导教师司海平
撰写日期：二〇二六年四月二十日
河南农业大学
毕业论文（设计）原创性声明
本人郑重声明：所呈交的毕业论文（设计），是本人在指导教师指导下，进行研究工作所取得的成果。除文中已经注明引用的内容外，本毕业论文（设计）的研究成果不包含任何他人创作的、已公开发表或者没有公开发表的作品的内容。对本毕业论文（设计）所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。本学位毕业论文（设计）原创性声明的法律责任由本人承担。
指导教师签名：
毕业论文（设计）作者签名：
年月日
河南农业大学
毕业论文（设计）版权使用授权书
本人完全了解河南农业大学关于收集、保存和使用学位毕业论文（设计）的规定，同意如下各项内容：按照学校要求提交毕业论文（设计）的印刷本和电子版本；学校有权保存毕业论文（设计）的印刷本和电子版，并采用影印、缩印、扫描、数字化或其它手段保存毕业论文（设计）；学校有权提供目录检索以及提供本毕业论文（设计）全文或者部分的阅览服务；学校有权按有关规定向国家有关部门或者机构送交毕业论文（设计）的复印件和电子版；在不以赢利为目的的前提下，学校可以适当复制毕业论文（设计）的部分或全部内容用于学术活动。
指导教师签名：
毕业论文（设计）作者签名：
年月日
目录
摘要I
AbstractII
1 引言1
1.1 研究背景与意义1
1.2 国内外研究现状1
1.3 主要内容与技术路线3
2 相关技术4
2.1 检索技术4
2.1.1 知识图谱检索技术4
2.1.2 向量检索技术4
2.1.3 BM25检索技术5
2.2 多路检索融合技术5
2.2.1 倒数排名融合（RRF）5
2.2.2 权重优化策略6

2.3 评估指标	6
2.4 系统架构	7
3 数据来源与处理	7
3.1 文本预处理	8
3.2 文档向量化与向量数据库构建	10
3.3 知识抽取与知识图谱构建	10
4 算法构建	10
4.1 知识图谱检索算法	11
4.1.1 知识图谱结构设计	11
4.1.2 检索流程设计	11
4.2 向量检索算法	12
4.2.1 文档向量化	12
4.2.2 查询检索	13
4.3 BM25检索算法	13
4.3.1 倒排索引构建	13
4.3.2 BM25评分计算	14
4.3.3 参数配置与检索流程	14
4.4 RRF融合算法	14
4.4.1 RRF评分公式	15
4.4.2 融合流程设计	15
4.5 贝叶斯优化算法	15
4.5.1 优化问题定义	15
4.5.2 贝叶斯优化流程	16
4.5.3 优化结果分析	16
5 实验结果与分析	16
5.1 实验环境与配置	16
5.1.1 硬件环境	16
5.1.2 软件环境	16
5.1.3 知识库配置	17
5.2 测试数据集	17
5.2.1 数据集构建	17
5.2.2 数据集示例	17
5.3 实验流程	18
5.3.1 实验准备阶段	18
5.3.2 单模块检索实验	18
5.3.3 多模块检索实验	18
5.4 实验结果	18
5.5 分析与讨论	19
5.5.1 单模块性能分析	19
5.5.2 检索模式互补性分析	19
5.5.3 融合方案性能分析	20
5.5.4 检索策略选择建议	20
6 系统实现	21
6.1 登陆与首页	21
6.2 病害诊断	22
6.3 检索测试	24
6.4 向量数据库可视化	25
6.5 知识图谱可视化	26
7 总结与展望	28
7.1 总结	28
7.2 展望	28
致谢	32

摘要

为解决小麦病害诊断过程中存在的信息检索效率低、专业知识分散、诊断准确性不足等问题，本研究构建了一种基于农业知识增强的小麦病害辅助诊断系统。系统采用知识图谱与检索增强生成（RAG）相结合的技术路线，通过Neo4j图数据库构建小麦病害领域知识图谱，利用ChromaDB向量数据库存储病害文献知识，并集成DeepSeek大语言模型实现智能诊断问答。研究设计了知识图谱检索、向量语义检索、BM25关键词检索三种检索方式，采用加权倒数排名融合（Weighted RRF）算法实现多路检索结果的融合。在包含700个问答对的测试数据集上对7种检索方案进行了系统评估，结果表明：单一检索方式中，向量检索的F1分数最高，达到65.87%，召回率为97.57%；混合检索方式中，知识图谱+向量检索+BM25三路融合效果最优，召回率达到100.00%，精确率为70.15%，F1分数为78.56%。通过贝叶斯优化确定最优融合权重配置为知识图谱权重4.785、BM25权重4.182、向量检索权重0.754。本研究构建的知识增强型诊断系统有效整合了结构化知识与非结构化文本，显著提升了小麦病害诊断的检

索效率和准确性，为农业智能化诊断提供了技术参考。

关键词：小麦病害；知识图谱；检索增强生成；多路融合检索；辅助诊断

Abstract

The system uses a combination of knowledge graphs and Retrieval-Augmented Generation (RAG) in its technical design. It builds a domain-specific knowledge graph for wheat diseases using the Neo4j graph database, stores disease-related literature knowledge in the ChromaDB vector database, and integrates the DeepSeek large language model to support intelligent diagnostic question answering. The system adopts a technical route combining knowledge graph and Retrieval-Augmented Generation (RAG), constructs a wheat disease domain knowledge graph using Neo4j graph database, stores disease literature knowledge with ChromaDB vector database, and integrates the DeepSeek large language model to realize intelligent diagnostic question answering. The study designed three retrieval methods: knowledge graph retrieval, vector semantic retrieval, and BM25 keyword retrieval, and adopted the Weighted Reciprocal Rank Fusion (Weighted RRF) algorithm to fuse multi-path retrieval results. A systematic evaluation of 7 retrieval schemes was conducted on a test dataset containing 700 question-answer pairs. The results show that among the single retrieval methods, the vector retrieval achieves the highest F1 score of 65.87% and a recall rate of 97.57%; among the hybrid retrieval methods, the three-way fusion of knowledge graph + vector retrieval + BM25 achieves the optimal effect, with a recall rate of 100.00%, a precision rate of 70.15%, and an F1 score of 78.56%. Bayesian optimization was used to determine the best weights for the fusion, with values of 4.785 for the knowledge graph, 4.182 for BM25, and 0.754 for vector retrieval.

The knowledge-enhanced diagnostic system developed in this work effectively combines structured knowledge with unstructured text data, significantly improving both the speed and accuracy of wheat disease diagnosis, and offers a practical technical reference for intelligent agricultural diagnosis applications.

Key words: Wheat Disease; Knowledge Graph; Retrieval-Augmented Generation; Multi-path Fusion Retrieval; Auxiliary Diagnosis

2. 1 引言		总字数：4380
相似文献列表		
去除本人文献复制比：0.7%(32) 去除引用文献复制比：0%(0) 文字复制比：0.7%(32) 疑似剽窃观点：(0)		
1	水平棚架式梨园疏果机器人车辆的果园障碍物检测方法研究 邱海阔 - 《大学生论文联合比对库》- 2024-04-18	0.7% (32) 是否引证：否
2	水平棚架式梨园疏果机器人车辆的果园障碍物检测方法研究 邱海阔 - 《大学生论文联合比对库》- 2024-05-27	0.7% (32) 是否引证：否
原文内容		

1 引言

1.1 研究背景与意义

作为三大主粮之一，小麦的年产量占到了粮食总产的三分之一以上。它不仅直接关系着老百姓的餐桌，也是支撑农业产业链、守护国家粮食安全的战略物资，小麦的产量和品质的波动牵连整个农业经济与农户的切身利益。但是在实际生产中，从种到收的漫长周期里，小麦常遭遇条锈病、赤霉病、白粉病和叶锈病等病害。这些病害来势猛、蔓延快、危害重，一旦错过防治窗口，轻则减产10%—30%，重则颗粒无收。这对农户来说就是血本无归，还会冲击粮食供应的稳定。过去小麦得了什么病，基本靠农户凭经验推断，或者专门请植保技术人员查看。这种判断方式非常依赖个人水平，而个人水平往往参差不齐，准确率难以保证。而且等到发现病情，往往已经扩散开来，响应总是慢半拍。因此这种方式满足不了当前规模化、集约化生产对快速防控的迫切要求。

最近几年，深度学习图像识别技术开始被引入作物病害诊断，病害的诊断效率有所提高，但落地推广时依然绕不开两个难题。第一个难题是，现有诊断模型大多采用深层架构，参数体量极大，不仅训练阶段消耗大量算力，而且部署时还依赖高性能计算硬件，很难适配田间常用的无人机、便携诊断终端这类边缘设备。也就是说，模型做得太“重”，在田间地头根本跑不顺。第二个难题集中在诊断的可靠性上。模型的训练几乎完全依赖图像表现特征，缺少小麦病理学领域的先验知识支撑，碰到症状高度相似的危害——如条锈病和叶锈病——就非常容易混淆。而在实际田块中，光照强弱无常、叶片相互遮挡、杂草与植株混杂是常态，这类复杂环境会让模型的诊断鲁棒性大幅滑坡，难以达到精准防控的生产要求。

1.2 国内外研究现状

国外关于小麦病害的研究已有许多科研成果。瑞士农业科技研究院（Agroscope）与苏黎世大学团队，解析欧洲小麦白粉菌（Bgt）群体进化，发现AvrPm17基因变异导致Pm17抗性失效，揭示病菌快速适应抗病品种的分子机制，为育种提供动态监测方案[1]。美国梅根·朗，马修·哈特利等在美国国立卫生研究院发表了利用深度学习网络与田间和温室图像对小麦病害进行分类的期刊[2]。荷兰瓦赫宁根大学与英国NIAB团队，利用高光谱成像与深度学习相结合的方法，首次构建包含1,447张小麦叶片单感染与双重感染高光谱图像的数据集，训练EfficientNet-2D卷积神经网络模型，实现对条锈病、白粉病和叶枯病（Septoria）单感染及共感染的精准分类，整体准确率达81%，揭示了不同病原共感染条件下的光谱交互特征，为田间病害早期

精准诊断提供了技术方案[3]。冈达尔大学与埃塞俄比亚生物技术研究所团队，利用包含褐锈病、茎锈病和黄锈病三类小麦锈病的CGIAR公开图像数据集，系统比较MobileNetV3、DenseNet121、ResNet50和EfficientNetB0四种预训练CNN架构的识别性能，发现MobileNetV3以97.7%的分类准确率最优。该模型因其轻量化特性适合部署于移动设备，为田间锈病的快速自动化识别提供了高效支持[4]。国际玉米小麦改良中心（CIMMYT）与Y. Hu、J. Crossa、S. Mondal、R. Singh、J. Poland、G. Bai、D. Wang、E. G. Bautista、F. Pinto及Q. Sun等人组成的合作团队，把超低空无人机表型技术和经过优化的YOLOv8深度学习模型结合在一起，构建了一个开放式的赤霉病图像数据集。这个数据集包含了4,867个病穗样本和106,801个健康穗样本。他们借助SHAP可解释性分析方法，明确了接种后10到20天是评估赤霉病的关键窗口期。在此基础上，团队对423个参试小麦品种进行了抗性分级，准确地划分出四个等级，而且各个等级的分类结果与田间专家的评价高度吻合。整体来看，该方法实现了小麦赤霉病大规模、自动化的表型分析与抗性动态分级，为育种者筛选抗病品种提供一个高效实用的工具[5]。

国内学者在这一领域同样取得了很多科研成果。张鹏等人针对春季小麦茎基腐病等病害的危害特征做了系统梳理，同时明确了麦田杂草的分类防控要点。他们提出了“冬前综合防控+春季分阶段防治”的策略，并配套给出了杂草差异化防除方案，为春季小麦病虫害的精准防控提供了一套切实可行的技术指导[6]。Saddam Hussain则把目光放在了小麦病害检测的痛点上，他构建了一个包含11510张图像的数据集并进行了样本增强，将YOLOv5m改进为YOLOv5-ShuffleNetv2，并在其中引入了注意力机制。改进后的模型在检测精度和效率上都优于传统模型，为小麦病害的快速检测提供了技术支撑[7]。侯俊关注的是小麦赤霉病的飞防优化，通过田间试验分析了助剂对小麦安全性和防效等方面的影响，明确了助剂在飞防中的高效性，验证了其提升飞防效果、助力农药减量的作用，这为滨州地区小麦赤霉病的绿色防控给出了科学依据[8]。尹利华等人注意到大田环境下小麦病害检测模型存在局限性，于是提出了OBS-YOLOv8：他们对主干和颈部网络做了优化并实现了轻量化处理。试验结果表明，该方法精确率达到91.3%，参数量只有2.8M，在性能提升的同时大幅降低了资源消耗，为移动端的田间检测提供了一条可行的路子[9]。

郝巧红团队也对YOLOv8模型做了优化：他们用五种数据增强方式扩充数据集，并在结构中融入了DySample和SA（Shuffle Attention）模块。改进后的模型mAP达到97.6%，抗干扰能力很强，能准确识别病害类型与发生区域，性能优于原模型和YOLOv9[10]。张刚山在山东的基地以“济麦22”为材料开展了试验，设置了多组对照来监测病害与生长指标。结果显示，混合用药组的控病效果达到72.7%，生长状况也最好；单施生物农药虽然效果稍弱，但更加生态友好。这为小麦病害的防治提供了科学参考[11]。李艳莉对小麦病害的早期诊断方法（包括常规识别和分子技术）以及综合防控技术（如预警系统和农业操作）做了梳理，她建议通过研发诊断工具、集成现有技术、培训农民等方式来提升防控效果，为防控工作的科学性提供了支撑[12]。王琦等人则专门针对小麦赤霉病，明确了其发病规律和多重危害，提出了农业、化学、生物三类防治技术，并构建了一套基于物联网的智能监测系统，能够实现实时预警与精准施药，为小麦生产安全提供了一套比较全面的解决方案[13]。康梦倩等人指出了农户在防治赤霉病时常陷入的三个误区，并提出了“预防为主”的策略：他们强调要在扬花初期就进行施药，建议轮换或混配杀菌剂，再结合品种选择、深翻等管理措施，从而降低抗性、提高防治效率[14]。刘会锦提出了优质小麦高产的四项推广策略，同时也为锈病、白粉病、纹枯病明确了防治路径：锈病依靠抗病品种加种子消毒，白粉病在病叶率达到标准时用药，纹枯病则要把握好播种期和返青期的用药时机，以此来保障小麦的优质高产[15]。房利梳理了无人机遥感在作物病害监测中的应用，明确了其在捕捉作物数据、服务病害管理方面的价值，并指出随着相关技术的进步，该技术已大面积见效，为后续研究搭建了基础框架并指明了识别算法的方向[16]。常升龙团队采集了小麦锈病图像，利用深度学习进行监测评估，他们发现注意力机制能够提升精度，改进后的Imp-Dense Net识别精度达到了98.32%，解决了传统管理中的痛点，也为锈病防控乃至其他作物的监测提供了借鉴[17]。冯子恒将手机与无人机影像结合起来，优化了算法并构建了小麦病害识别与监测模型，他发现经过优化的算法以及RF（随机森林）等模型精度最优，植被指数融合模型也有很好的效果。这为精准诊断提供了技术支持，有助于病害防控和保障粮食安全[18]。

纪让军团队分析了陕西岐山小麦白粉病的发生特点，指出暖冬、品种抗性弱、秸秆还田等是重发原因，并提出综合防治对策[19]。鲍文霞团队提出空间深度转换域自适应检测网络（SPD-DANet），利用域自适应学习实现了无人机图像小麦赤霉病的无监督检测[20]。卢立明团队从病害监测、药剂配制、参数设定到效果评估，探讨了无人机飞防小麦赤霉病的技术流程与应用效果[21]。李明轩构建了包含八类病害的小麦病害数据集，提出双向跨尺度注意力网络（BiCS-WDNet）及检测系统，提高了病害检测精度[22]。[马超伟团队提出一种基于改进YOLOv8的轻量化小麦病害检测方法](#)，通过轻量化骨干网络和注意力机制在降低参数量的同时提升了检测精度[23]。蒋玲研究结合注意力机制的轻量化小麦病害检测模型，并基于Jetson Xavier NX边缘设备构建了实时监测系统[24]。廖子涵提出结合YOLOv5s与Grab Cut、Otsu的分割方法及多路CNN特征融合，解决了复杂背景和麦穗遮挡下的小麦病害识别问题[25]。

总的来看，国外在小麦病害领域成果突出，主要集中在病菌群体进化的分子机制解析，以及深度学习结合图像技术进行病害分类等方向，为抗病育种和病害检测提供了理论和工具上的支持。国内研究紧跟国际前沿，成果也十分丰富，重点放在病害检测模型优化、防控策略制定、防治技术对比、早期诊断和综合防控等多个维度。大家通过改进YOLO系列等模型提升了检测精度，探索化学防治与生物防治相结合的策略，明确了常见病害的防治路径，逐渐形成了多元化的技术体系，为小麦病害精准高效防控及优质高产提供了从理论到落地的技术支撑。

1.3 主要内容与技术路线

本研究建立的小麦病害智能诊断技术体系，以农户在田间观察到的异常描述作为起点。系统先借助实体识别抽取出血害、症状、生育期等关键信息，然后在小麦病害知识图谱中查找与之关联的病理知识。这些结构化的知识会被转化为自然语言文本，再根据诊断需要组装成知识增强的提示模板，最后由大语言模型输出病害诊断结果和相应的防治建议。为了给这套流程提供底座支撑，本研究依托DeepSeek大模型构建了面向小麦病害辅助诊断的知识基础。

具体来说，在Neo4j中建立了一个包含7类核心实体、6种语义关系的小麦病害知识图谱，同时配套搭建了向量数据库和BM25文本检索模块，三者一起构成了一个三维检索体系。实验时，对每种检索方式的单独运行和组合使用都进行了测试，采用RRF融合策略并配合贝叶斯优化，经过50次迭代找到了搜索效果最好的权重组合。以召回率、精确率、F1分数和命中率作为验证指标，确定了性能最佳的检索方案。把这个方案检索到的知识片段嵌入提示模板后，交给DeepSeek模型来完成推理诊断。整个系统前端用Streamlit搭建，后端基于Python和LangChain框架并与Neo4j等组件集成，最终实现了从文字描述输入到诊断结论和防控方案输出的全流程闭环。

相似文献列表

去除本人文献复制比：1%(37) 去除引用文献复制比：1%(37) 文字复制比：1%(37) 疑似剽窃观点：(0)

1	基于多元信息引导的遥感图像舰船目标细粒度识别方法研究	1.0% (37)
	刘潇(导师：管乃洋) - 《军事科学院硕士论文》 - 2025-05-30	是否引证：否
原文内容		

2 相关技术

本章节将围绕本系统实现所依托的核心技术体系展开梳理与介绍，重点阐述多检索融合框架中涉及的关键技术原理与实现思路。为后续系统设计、实现与实验验证提供坚实的理论支撑与技术基础。

2.1 检索技术

2.1.1 知识图谱检索技术

在病害诊断中，很多知识天然就是“网状”的——某种病会表现出一系列症状，而同一个症状又可能对应好几种病，再加上病原、传播条件、适用农药等等，相互之间牵扯极多。如果把这些信息放到普通的关系型表格里，关联的查询会变得很绕。而知识图谱的思路恰好能解决这个问题：它用“实体—关系—实体”这样的三元组把领域知识组织起来，直观地刻画出各种概念之间的真实联系。根据小麦病害的实际特点，可以梳理出几类核心实体，包括病害、症状、病因、农药等，以及它们之间的主要关系，比如HAS_SYMPTOM（具有症状）、CAUSED_BY（由...引起）、USES_PESTICIDE（使用农药）等，构成一个相对完整的知识网络。

实际存储和查询选用了Neo4j图数据库。之所以用它，是因为图数据库天生为遍历关系而设计，查询一条“某病害→某症状→对应药剂”的路径，比写多表关联的SQL要直接得多。在系统里，用户问题中一旦提取出病害名称、症状关键词或农药名称，这样就可以用Cypher查询语句沿着关系边去匹配、扩展路径，把关联的病害详情和防治建议一并拉取出来，作为诊断的可靠依据。这样得到的答案不是靠猜测，而是基于既定的农学知识逻辑，解释性也更强。

2.1.2 向量检索技术

然而光靠知识图谱无法达到理想的结果。田间农户或基层植保人员的提问方式常常不规范，“叶片上有黄点点”“秆子上长白毛”这类描述，很少直接使用标准术语。这时候如果还指望图谱做精确的字符串匹配，大概率会扑空。这就引出了向量检索，它本质上是在做语义匹配。

先用一个预训练的语言模型把文本变成高维空间的稠密向量。提问时，用户输入的自然语言也被同一个模型映射成向量，然后在向量数据库里计算它和已有文档片段的语义距离。距离的衡量可以用余弦相似度，也可以选欧氏距离，本研究采用了余弦相似度，因为它更关心方向的一致性，受文本长度影响更小。这种做法有一个很实在的好处：对同义词、近义词和不同句式有天然的包容度，“起锈斑”和“锈色粉状物”在向量空间里会靠得很近，系统就能把相关的内容检索出来，避免了关键词完全对应才算命中的缺点。

具体的向量存储和检索引擎用的是ChromaDB。知识库里的文档片段先被逐一编码成向量，存入ChromaDB后，内部会自动构建近似最近邻索引。而在查询阶段，系统会先对用户的问题进行向量化，然后再去库中快速找出最相似的若干个文档片段，最后再返回对应的病害诊断信息。这样一来，即便是语义模糊的提问也有了较好的支撑，不至于因为用词口语化就直接失效。

2.1.3 BM25检索技术

然而向量检索也有自己的局限性。当面临非常生僻的专有名词、具体的农药商品名，或者一些在训练语料里出现极少的专业表述时，语义模型容易产生偏差，检索效果会下降。因此，本研究又引入了BM25（Best Matching 25）这一经典算法作为补充。

BM25是一种基于概率检索模型来排序的方法，其核心关注点在于词频、逆文档频率和文档长度归一化这三个方面。通俗地讲，如果某个查询词在一篇文档里反复出现，而在整个文档集中却很少见，那么这篇文章就很有可能是用户想要的。同时，算法还对文档长度做了修正，以免得长文档因为词多而得到不合理的偏袒。这些特点使得BM25在精确匹配关键词的任务上表现突出，计算效率也理想，尤其适合检索那些带有明确病害名称、病原菌拉丁名或者化学药剂名称的文本。

在具体实现上，本研究选用了rank_bm25库。首先先为知识库里的全部文档做分词并构建倒排索引；当用户查询中包含具体的病害名或专业术语时，BM25可以迅速依据词的统计特征给出分数并排序，将最贴近的文档排到最靠前的位置，定位高效可靠。通过这一机制，即使用户的提问很短，只是报了一个病名或药名，系统也能给出高度相关的参考材料。这极大地提高了系统的实用性。

2.2 多路检索融合技术

单独依靠上述任何一种检索方式，效果都存在上限。知识图谱擅于结构化的逻辑查找，向量检索能理解语义，BM25则精于词项精准命中，三者的优势其实是互补的。实际运行时，同一个问题可能既需要模糊的语义联系，也需要对专有名词的一击即中，因此对多路检索结果进行有效融合是非常重要的。

2.2.1 倒数排名融合（RRF）

融合多个不同来源的检索结果，主要挑战在于它们的得分尺度完全不在一个量级。知识图谱检索返回的是确定性的路径命中，没有连续的分值；向量检索给出的是余弦相似度值，分布在[-1, 1]或[0, 1]区间；而BM25的得分是一个非负数值，随查询和文档变化很大。直接把这些分数加权相加不但没意义，反而会引入巨大噪声。因此，本研究选用了倒数排名融合（Reciprocal Rank Fusion, RRF），这种方法只依赖于每个结果在各自列表里的排序位置，而无需关心原始分数的具体数值。

具体实现上，先让向量检索、BM25检索和知识图谱检索各自独立地返回前10个结果，然后按照每条结果在其对应子检索中的排名，套入RRF公式换算出一个融合分数，最后把所有通路的结果混合起来按融合分重新排序，截断返回前5个最相关的文档

。RRF实现简洁、计算开销小，而且在跨检索源融合中表现稳定，非常适合本研究中三路异构检索的集成场景。即便某一路检索给出的排序有一定偏差，因为排名信息在融合时被平滑处理，也不会导致整体顺序出现严重的偏差。

2.2.2 权重优化策略

在基本的RRF融合里，默认各通路的贡献是平等的。然而在实际应用中，不同类型的查询对各种检索方式的依赖程度并不相同。例如，一条以模糊症状为主的问句，向量检索应被赋予更高的权重；而一个几乎全是专有名词的查询，BM25和知识图谱的权重理应更高。为了让融合效果尽可能好，每个检索通路都被分配了不同的融合权重，然后去寻找一组最优的权重配置。

贝叶斯优化可以很好地解决权重配置的问题。贝叶斯优化特别适用于目标函数评估代价很高的场合——每评估一个权重组合，都需要跑一遍完整的检索流程并计算评估指标，耗时是可观的。它的基本思路是，先用高斯过程等代理模型去近似真实的性能曲面，然后通过采集函数（例如期望改进EI）去选择下一个最有潜力提升性能的权重重点进行实测。经过预设的50次迭代，算法就能够在较少的试验次数内，锁定近乎全局最优的权重，使融合检索的性能达到最佳。通过此方式确定的参数具有量化依据，而非凭主观经验。

2.3 评估指标

在评价检索效果时，本研究选用了召回率、精确率、F1分数和命中率这四个在信息检索里的核心指标，从不同侧面来衡量小麦病害诊断系统的检索性能。下面分别说明每个指标的含义、计算公式和在本系统中的实际应用方式。

召回率（Recall）主要看系统检索的全面性。它指的是检索出的相关文档数占有所有相关文档总数的比例，计算公式为：

(1)

也就是检索到的相关文档数除以全部相关文档数。在我们的系统里，召回率是按病害名称来统计的，目的是判断检索结果有没有覆盖用户查询中涉及的每一种病害。比如用户问“小麦条锈病的症状”，系统就会检查检索结果里是否出现了条锈病相关的文档，缺了就算漏检。

精确率（Precision）关心的则是检索的准确性，它定义成检索出的相关文档数与检索出的文档总数的比值，公式为：

(2)

在本系统中，精确率同样按病害名称口径计算，用来衡量返回结果里相关病害文档所占的比例。精确率越高，意味着混进来的无关信息越少，使用者就能更快定位到有用的内容。

F1分数是精确率和召回率的调和平均，将两者的平衡性统一到一个数值上，公式为：

(3)

本系统把F1分数作为评估检索性能的主要依据，并直接用作贝叶斯优化的目标函数。通过调整各检索模块的融合权重，让F1分数尽可能高，从而在召回率和精确率之间找到一个相对理想的平衡点。

命中率（Hit Rate）是一个比较基础的底线指标，它看的是检索结果里至少能命中一个相关文档的查询占多大比例，计算方式为：命中率=命中相关文档的查询数/总查询数。在本系统的应用场景中，命中率反映了系统最基本的有效性——如果命中率很高，说明绝大多数查询怎么都能带回至少一条相关文档，这保证了系统在真实使用时不至于让用户空手而归，为系统的可用性提供了基本的保障。

2.4 系统架构

本系统采用多检索融合架构，整体流程如图1所示：用户输入查询后，由混合检索协调器统一调度，并行调用三类检索引擎——基于Neo4j数据库的知识图谱检索，通过实体与关系匹配实现结构化知识的精准召回；基于ChromaDB向量数据库的向量检索，利用语义相似度匹配实现非结构化文本的深层语义召回；针对知识库文档的BM25检索，通过关键词匹配实现传统信息检索的高效召回；三类检索结果汇总后，通过RRF倒数排名融合算法进行结果整合与重排序，最终生成面向用户需求的分析报告。

图1 系统架构图

4. 3 数据来源与处理		总字数：2986
相似文献列表		
去除本人文献复制比：17.2%(513) 去除引用文献复制比：14.1%(420) 文字复制比：17.2%(513) 疑似剽窃观点：(0)		
1	浅谈小麦常见病虫害防治技术 王洪升；- 《种子科技》- 2021-10-20	15.6% (465) 是否引证：否
2	(完整版)小麦病虫害防治. - 《互联网文档资源 (https://www.360docs.)》- 2024	1.2% (35) 是否引证：否
3	玉米虫害生物防治方法. - 《网络 (https://www.360docs.)》- 2025	1.1% (33) 是否引证：否
4	察隅玉米高产种植技术应用和病虫害防治策略的具体实践综述 扎西卓玛；- 《种子世界》- 2025-12-08	0.8% (25) 是否引证：否
原文内容		

3 数据来源与处理

构建一个实用的小麦病害诊断系统，首先需要一批质量可靠、覆盖全面的基础数据。本研究使用的资料主要来自中国知网、安徽省农业农村厅和世界农化网三个渠道。

在数据处理阶段，整体技术路线被设计成两条并行的处理流水线：一条是面向语义检索，将文档转化为可供向量匹配的数量表示；另一条则是面向结构化查询，将文本中的知识提取出来构建为图结构。这两条管线都以原始文档为起点，同步推进

，这样做的目的是使系统不单单能应对口语化的模糊描述，也能够支持精确的逻辑查询，这二者在底层数据上各司其职、相互补充。

3.1 文本预处理

无论是做语义向量化还是知识抽取，第一步都必须对原始语料进行清洗和切分，尽可能去掉噪声，保留高密度的知识文本，并将其分割成合适的单元。

文本清洗主要依赖Python的正则表达式构建多级过滤规则。从数据库和网络平台直接获取的文档中，往往夹杂着大量与病害本身无关的内容，如期刊的卷号、期号、页码、作者单位、页眉页脚、参考文献列表、DOI链接以及英文摘要等。若不对这些信息进行处理而直接送入后续环节，既占用存储和计算资源，又容易干扰语义编码和实体识别。因此，我们按照优先级依次对这些非核心内容进行剥离。清洗之后，单篇文档的字符规模平均压缩到原来的70%左右，文本噪声显著下降，有效信息的密度明显提高。

清洗完的文本仍不能直接用于向量检索，因为向量检索更适合把段落或句子这样相对完整的语义单元作为基本的检索粒度。因此，本研究设计了一个递归字符分割算法来处理分块。在参数设置上，基本块的大小定在500个字符，相邻两块之间会保留50个字符的重叠区。设置这些重叠区主要是为了防止切分点恰好卡在一个完整概念的正中间，导致上下文的语义被割裂开。实际切分时，算法会严格按照事先定好的分隔符优先级来挑选切分位置：最优先看段落边界（也就是双换行符），其次找句子结束标点（句号、问号、感叹号），再接着是分号和逗号，最后是空格。这种有层次的分割策略，能够让切分点尽可能落在自然的语义边界上，这样一来，每个文档片段即使被单独取出来，也依然带着相对完整的意思，对后续的语义匹配较为有利。

文本预处理前后的对比如下：

表1 文本预处理前后对比

处理前文本	处理后文本
DOI: 10.19904/j.cnki.cn14-1160/s.2021.19.046 浅谈小麦常见病虫害防治技术 王洪升 (诸城市相州镇党委, 山东潍坊262200) 摘要: 小麦是我国重要的粮食作物之一, 在我国广泛种植。小麦生产与国家粮食安全紧密相连。小麦种植过程中, 很容易受到病虫害侵扰, 导致其质量、产量大幅下降。通过分析小麦种植过程中常见的病虫害, 采取不同时期病虫害防治措施, 以期稳定小麦生产提供帮助。 关键词: 小麦; 病虫害; 防治措施 文章编号: 1005-2690 (2021) 19-0097-02 中国图书分类号: S435.12 文献标志码: B 1 防治原则 小麦病虫害防治应贯彻预防为主、综合治理的原则, 以农业手段为主, 化学、物理和生物手段为辅的原则, 在最大程度上种植出绿色无公害的小麦。 2 常见小麦病虫害 2.1 条锈病 条锈病是一种流行性、毁灭性疾病, 突发性强、蔓延速度快, 一旦发现必须及时用药。该病害主要为害小麦叶片、叶鞘、茎秆及穗部[1]。条锈病发病初期, 麦叶会出现几层鲜黄色的夏孢子堆, 呈小长条状, 平行于叶脉; 小麦即将成熟时, 叶鞘出现黑色、狭长形的条状疱斑, 即冬孢子堆[2]。该病害分布广、破坏面积大, 极易造成小麦大量减产。	小麦常见病虫害防治技术 简介 小麦是我国重要的粮食作物之一, 在种植过程中容易受到病虫害侵扰, 导致其质量、产量大幅下降。小麦病虫害防治应贯彻预防为主、综合治理的原则, 以农业手段为主, 化学、物理和生物手段为辅。 常见小麦病害 一、条锈病 条锈病是一种流行性、毁灭性疾病, 突发性强、蔓延速度快, 一旦发现必须及时用药。该病害主要为害小麦叶片、叶鞘、茎秆及穗部。 症状特点: 发病初期, 麦叶会出现几层鲜黄色的夏孢子堆, 呈小长条状, 平行于叶脉; 小麦即将成熟时, 叶鞘出现黑色、狭长形的条状疱斑, 即冬孢子堆。该病害分布广、破坏面积大, 极易造成小麦大量减产。

处理前文本处理后文本

DOI: 10.19904/j.cnki.cn14-1160/s.2021.19.046

浅谈小麦常见病虫害防治技术

王洪升

(诸城市相州镇党委, 山东潍坊262200)

摘要: 小麦是我国重要的粮食作物之一, 在我国广泛种植。小麦生产与国家粮食安全紧密相连。小麦种植过程中, 很容易受到病虫害侵扰, 导致其质量、产量大幅下降。通过分析小麦种植过程中常见的病虫害, 采取不同时期病虫害防治措施, 以期稳定小麦生产提供帮助。

关键词: 小麦; 病虫害; 防治措施

文章编号: 1005-2690 (2021) 19-0097-02

中国图书分类号: S435.12

文献标志码: B

1 防治原则

小麦病虫害防治应贯彻预防为主、综合治理的原则, 以农业手段为主, 化学、物理和生物手段为辅的原则, 在最大程度上种植出绿色无公害的小麦。

2 常见小麦病虫害

2.1 条锈病

条锈病是一种流行性、毁灭性疾病, 突发性强、蔓延速度快, 一旦发现必须及时用药。该病害主要为害小麦叶片、叶鞘、茎秆及穗部[1]。

条锈病发病初期, 麦叶会出现几层鲜黄色的夏孢子堆, 呈小长条状, 平行于叶脉; 小麦即将成熟时, 叶鞘出现黑色、狭长形的条状疱斑, 即冬孢子堆[2]。该病害分布广、破坏面积大, 极易造成小麦大量减产。 小麦常见病虫害防治技术

简介

小麦是我国重要的粮食作物之一, 在种植过程中容易受到病虫害侵扰, 导致其质量、产量大幅下降。小麦病虫害防治应贯彻预防为主、综合治理的原则, 以农业手段为主, 化学、物理和生物手段为辅。

常见小麦病害

一、条锈病

条锈病是一种流行性、毁灭性疾病, 突发性强、蔓延速度快, 一旦发现必须及时用药。该病害主要为害小麦叶片、叶鞘、茎秆及穗部。

症状特点:

发病初期, 麦叶会出现几层鲜黄色的夏孢子堆, 呈小长条状, 平行于叶脉; 小麦即将成熟时, 叶鞘出现黑色、狭长形的条状疱斑, 即冬孢子堆。该病害分布广、破坏面积大, 极易造成小麦大量减产。

3.2 文档向量化与向量数据库构建

为使预处理后的文档片段参与语义检索，需要把它们转成计算机能够处理的数值向量，并且搭好高效的索引。在语义向量化这一步，本研究采用了sentence-transformers库里的预训练模型moka-ai/m3e-base。这个模型基于BERT架构，是专门为中文语义表征任务优化过的，在好几个中文语义相似度评测里表现都比较稳定。文本送进去先分词、编码、池化，最后输出一个768维的稠密向量。为了后续相似度的稳定性，生成的向量全部做了L2归一化处理，这样一来，两个向量之间的欧氏距离就能直接反映语义上的远近，避免了向量长短不一样造成的偏差。

向量化之后的数据需要存下来，并支持高效的检索。本研究选用ChromaDB 0.4.22作为向量数据库。在实际操作中，先建立一个持久化集合，然后再把文档片段向量、对应的原文，以及来源文件名、分块索引这些元数据分批写入。ChromaDB内部会自动建起HNSW图索引，支持基于L2距离的近似最近邻搜索，即使在向量规模比较大的情况下，相似度查询也能控制在毫秒级别。最终形成了一个稳定的本地持久化向量库，为后面的检索增强生成环节提供了数据支撑。

3.3 知识抽取与知识图谱构建

对于需要结构化查询和逻辑推理的诊断任务，仅有向量检索是不够的，还需要构建一个能刻画病害、症状、病因和防治措施之间复杂关联的知识图谱。

考虑到小麦病害领域的术语体系相对封闭，实体类别有限，且描述模式比较规范，本研究采用了规则匹配与词典匹配相结合的方式知识抽取，而没有直接引入依赖大规模标注的深度学习模型。具体做法是，先构建一个覆盖37种病害名称、典型症状和常用化学药剂的领域词典，再利用 Jieba 分词工具对清洗后的文本进行细粒度分词，通过词典匹配识别出病害、症状、药剂等8类实体。同时，基于对大量农业技术文本的分析，本研究总结出一批高频的句法模式，例如“XX的症状为XX”“XX由XX引起”“XX可选用XX进行防治”等，通过模式扫描来捕捉实体之间的语义关联，设计了HAS_SYMPTOM、CAUSED_BY、USES_PESTICIDE 等7类关系。

抽取出的结构化知识以图的形式存入Neo4j 5.12.0图数据库。通过neo4j-driver驱动执行 Cypher查询，实体被逐批创建为节点，关系被作为有向边连接对应的实体节点。每个实体节点用名称属性做唯一标识，每一条关系边都显式地记录了病害与它的症状、病原或防治方法之间的知识连接。最终构建的领域知识图谱包含8类实体节点和7类关系边，通过Cypher语句可以灵活地进行结构化的路径查询和子图检索。

至此，原始的文本语料被转换成了两种相互补充的知识形态：一种是由语义向量索引支撑的近似匹配与模糊搜索，另一种是由图结构承载的精确领域逻辑。二者共同构成了诊断系统底层的数据基础设施，使系统在遇到不同类型的提问时，都能找到合适的知识来源加以应对。

指 标	
疑似剽窃文字表述	
1. 1 防治原则	小麦病虫害防治应贯彻预防为主、综合治理的原则，以农业手段为主，化学、物理和生物手段为辅的原则，在最大程度上种植出绿色无公害的小麦。
2 常见小麦病虫害	
2.1 条锈病	条锈病是一种流行性、毁灭性疾病，突发性强、蔓延速度快，一旦发现必须及时用药。
2. 小麦常见病虫害防治技术	
简介	小麦是我国重要的粮食作物之一，在种植过程中容易受到病虫害
3. 小麦病虫害防治应贯彻预防为主、综合治理的原则，以农业手段为主，化学、物理和生物手段为辅	
4. 常见小麦病害	
一、条锈病	条锈病是一种流行性、毁灭性疾病，突发性强、蔓延速度快，一旦发现必须及时用药。该病害主要为害小麦叶片、叶鞘、茎秆及穗部。
症状特点：	发病初期，麦叶会出现几层鲜黄色的夏孢子堆，呈小长条状，平行于叶脉；小麦即将成熟时，叶鞘出现黑色、狭长形的条状疱斑，即冬孢子堆。该病害分布广、破坏面积大，极易造成小麦大量减产。
5. 4 算法构建	总字数：6032
相似文献列表	
去除本人文献复制比：0%(0) 去除引用文献复制比：0%(0) 文字复制比：0%(0) 疑似剽窃观点：(0)	
原文内容	

4 算法构建

诊断系统的核心性能，很大程度上取决于底层的检索算法如何设计。本研究分别构建了知识图谱检索、向量检索和BM25检索三条相对独立的检索方式，再通过RRF融合与贝叶斯优化算法，把它们整合成一个更均衡的检索层级。下文将逐一说明各算法的思路、结构和具体流程。

4.1 知识图谱检索算法

知识图谱检索的出发点，是利用结构化的知识网络来做精准匹配。相较于全文搜索，这种检索方式更擅长沿着实体间已经定义好的关系直接定位，无需在全文里猜测关联。系统中构建的图谱涵盖了病害、症状、病因、农药等实体，以及HAS_SYMPTOM、CAUSED_BY、USES_PESTICIDE等关系。用户在提问时，一旦有实体被命中，图谱就可以顺着关系边快速返回相关病害信息，尤其适合目标明确的专项查询。

4.1.1 知识图谱结构设计

实际搭建的图谱包含8类实体节点和7类关系边。实体层面，除了病害、症状、药剂之外，还根据实际需求补充了发病条件、防治方法、传播途径、发病时期和危害部位，使知识覆盖更完整。关系层面，设计了HAS_SYMPTOM（病害→症状）、HAS_CONDITION（病害→发病条件）、HAS_CONTROL（病害→防治方法）、USES_PESTICIDE（病害→药剂）、HAS_TRANSMISSION（病害→传播途径）、HAS_STAGE（病害→发病时期）、AFFECTS_PART（病害→危害部位）。所有数据都用Neo4j图数据库存放，这样可以借助Cypher查询语言进行高效的图遍历和模式匹配，支撑后续多种检索策略。

4.1.2 检索流程设计

知识图谱检索被拆成三个主要阶段，分别是关键词提取与分类、多策略分层检索以及结果映射，从而确保从用户输入到文档返回的过程可控。

第一阶段，关键词提取与分类。系统先用Jieba分词工具对用户查询做分词，同时剔除预定义的停用词。这些停用词涵盖“什么”“怎么”“如何”“症状”“防治”等四十多个功能词，因其本身不携带病害判断所需的实质信息。之后，按照语义特征把关键词划为两类：病害关键词和症状关键词。判断依据是词汇中是否含有“病”“锈”“霉”“腐”“枯”“粉”“矮”“黑”“斑”等特征字符，有则归入病害关键词，其余的归入症状关键词。这一逻辑的直接作用在于：病害关键词可以直接去定位病害实体，而症状关键词则通过关系链路反查可能的病害，互不干扰。

第二阶段，多策略分层检索。根据关键词的类别，系统会执行不同的Cypher查询，并给命中结果赋予有差异的优先级分数，以反映不同匹配方式的可靠程度。

（1）病害名称匹配检索：对于病害关键词，运行类似MATCH (d:Disease) WHERE d.name CONTAINS \$keyword RETURN d.name的查询，在病害名称上执行包含匹配。命中的结果赋予较高的优先级分数10分，每次查询最多返回5个病害实体。

（2）症状关联检索：取前3个症状关键词，用下面的查询沿着HAS_SYMPTOM关系反向寻找病害：MATCH (d:Disease)-[:HAS_SYMPTOM]->(s:Symptom) WHERE s.desc CONTAINS \$keyword RETURN DISTINCT d.name。这种反向推导在用户主要描述症状时尤为关键，命中结果赋予中等的优先级分数5分。

（3）病因关联检索：同时执行 MATCH (d:Disease)-[:CAUSED_BY]->(c:Cause) WHERE c.desc CONTAINS \$keyword RETURN DISTINCT d.name，通过病因描述查找相关联的病害。因为病因与病害的对应关系有时不如症状直接，因此赋予较低分数，3分。

（4）药剂关联检索：如果关键词涉及农药名称，执行MATCH (d:Disease)-[:USES_PESTICIDE]->(p:Pesticide) WHERE p.name CONTAINS \$keyword RETURN DISTINCT d.name，通过药剂使用关系反查病害。命中的赋予4分。

检索中设置了一个重要的去重规则：同一个病害仅保留首次命中时的分数，不因多次命中而重复累加，这样能避免个别实体因关系稠密而过度占优。最终所有命中的病害先按分数降序排列，分数相同的再按病害名称升序排列，以保持输出次序的稳定。

第三阶段，病害-文档映射。从图谱中得到的病害名称不能直接返回给用户，还需要对应到知识库中的原始文档。本研究采用三级映射策略：首先做精确匹配，去掉病害名称前的“小麦”前缀后，直接与文档名进行字符串比对；若匹配失败，再用编辑距离计算模糊相似度，阈值设为0.6，高于这一值的文档被认为匹配成功；对于仍有命名差异的情况，通过预定义的映射字典做同义词转换。所有映射完成后，将图谱中得到的分数做归一化处理（除以10），按最终分数返回Top-K结果。

4.2 向量检索算法

向量检索的核心在于语义层面的相似性，而非字面一致。这恰好弥补了图谱检索对模糊自然语言支持的不足。算法分成文档向量化和查询检索两大块，下面将详细说明各步骤。

4.2.1 文档向量化

文档向量化的整个流程拆成了文档加载、文本预处理、文本分块、向量编码和向量存储五个环节。

（1）文档加载：系统从知识库目录里把所有TXT格式的病害知识文档读进来。共计覆盖小麦条锈病、白粉病、赤霉病等四十多种常见病害。

（2）文本预处理：文本的预处理用多级正则表达式做清洗，将HTML标签、特殊字符、多余的空白去除，统一转成UTF-8编码。具体来说，期刊的卷期信息、页码标记、作者单位、参考文献列表、DOI链接这些都得剥掉，还有中图分类号、文献标志码、文章编号等期刊的元信息也一样处理。除此之外，收稿日期、作者简介、基金项目这类跟病害知识本身没什么关系的学术元数据也要一并清除，表格里的分隔线和引用标记也不会保留。经此处理，留下来的核心内容的纯净度显著提升。

（3）文本分块：采用了递归字符分割的方法，基本块大小定在500个字符，相邻两块之间留50个字符的重叠。切分的顺序严格按分隔符的优先级来：最先看双换行（段落边界），然后是单换行（句子边界），接着是句号、分号、逗号，最后才是空格。按此层次切分，分出来的点基本都落在自然的语义边界上，每个片段单独提取时仍保留相对完整的语义信息。

（4）向量编码：用的是预训练的Sentence Transformers模型moka-ai/m3e-base。这模型是BERT架构的中文变体，专门为中文语义表征做了优化，输出768维的稠密向量。文本进去以后经过分词、Transformer编码和池化，得到的向量最后再做一次L2归一化。归一化之后，任意两个向量的余弦相似度可通过点积直接计算，语义匹配更准确，相似度比较的时候也更稳定。

（5）向量存储：选用ChromaDB作为向量数据库。每个文档片段存入时会附上向量、原始文本以及元数据（来源文件名、块索引等）。ChromaDB内部采用HNSW索引结构，能够以近似最近邻方式快速检索，复杂度约为 $O(\log n)$ ，可支撑大规模向量检索

4.2.2 查询检索

查询检索同样分为查询预处理、查询向量化、相似度计算和文档映射四个步骤。

(1) 查询预处理：对用户输入施加与文档相同的预处理，去掉特殊字符并统一编码，使查询与文档处于同一表示空间。

(2) 查询向量化：用同一个moka-ai/m3e-base模型将查询文本编码成向量，保持模型一致。

(3) 相似度计算：本系统采用余弦相似度作为向量语义匹配的核心度量标准。ChromaDB向量数据库基于余弦相似度计算查询与文档的语义相关性。余弦相似度公式为：

$$\text{CosineSimilarity}(Q, D) = \frac{Q \cdot D}{\|Q\| \times \|D\|} \quad (4)$$

其中，Q为查询向量，D为文档向量， $Q \cdot D$ 表示向量点积， $\|Q\|$ 和 $\|D\|$ 分别为向量的L2范数。余弦相似度范围在 $[-1, 1]$ 区间，值越大表示向量方向越相似。余弦距离公式为：

(5)

相似度分数转换公式为：

$$\text{SimilarityScore} = \frac{1 + \text{CosineDistance}}{2} \quad (6)$$

余弦距离转换为 $[0.5, 1]$ 区间的相似度分数，值越大表示查询与文档的语义越相似。检索时返回相似度最高的Top-K个文档片段。

(4) 文档映射：返回的是一些文档片段，需要映射回原始文档。这里同样采用三级策略：优先通过元数据中的source字段直接定位源文件；若失败，则取文档片段的前150个字符与知识库文档内容做反向匹配；再不行，就计算字符重叠度，选重叠度最高的文档作为来源。映射完成后，按相似度降序输出最终结果。

4.3 BM25检索算法

4.3.1 倒排索引构建

这个阶段依次完成文档加载、分词、词频统计和索引构建。

(1) 文档加载：与向量检索共用同一套TXT知识库，确保两者的底层数据一致，结果可对比。

(2) 分词处理：用Jieba做中文分词，过滤掉长度为1的单字词，减少噪声。Jieba的前缀词典分词结合HMM新词发现，在本领域文本上具备足够的准确率。

(3) 词频统计：统计每个词在文档中出现的次数，构建词频字典；同时记录每个词出现的文档数，用于后续IDF计算。此外，还要记下每个文档的长度和所有文档的平均长度，用于归一化。

(4) 索引构建：建立从词元到文档ID及词频的倒排字典，支持 $O(1)$ 时间复杂度的词元查找，为快速评分打下基础。

4.3.2 BM25评分计算

BM25算法的核心评分公式为：

(7)

其中 f 为查询词在文档D中的词频， N 为文档D的长度（词元数量）， $avgdl$ 为平均文档长度， b 为词频饱和度参数，控制词频增长的边际效应。 k_1 为文档长度归一化参数，控制长文档的惩罚程度。

IDF（逆文档频率）计算公式为：

(8)

其中 N 为文档总数， n 为包含查询词的文档数量。IDF值越高，说明词的区分能力越强。

4.3.3 参数配置与检索流程

本系统采用BM25Okapi变体，将 k_1 设为1.5， b 设为0.75。这个组合在多数文本检索任务中表现稳定：时，词频增长到3到4次后就趋于饱和，不会让少数高频词过度影响排序； $b=0.75$ 则对长文档施加适度的惩罚，避免长文档因为词多而天然占优。

具体检索流程是：对用户查询进行Jieba分词并过滤短词，计算每个查询词，然后遍历包含这些词的文档并累加BM25得分，最后按得分降序返回Top-K结果。只有得分大于0的文档才会被保留，从而自然过滤掉完全不相关的噪声项。

4.4 RRF融合算法

三路检索输出的分数体系和量纲完全不同，直接数值相加毫无意义。倒数排名融合（RRF）的策略是只看排名、不看绝对分数，从而将不同通路的结果整合成一份统一排序，降低单模块偏差带来的风险。

4.4.1 RRF评分公式

RRF算法核心公式：

(9)

其中 d 为待融合的文档， w_i 为第 i 个检索系统的权重， r_i 为文档 d 在第 i 个检索系统中的排名（从1开始）， k 为平滑常数，用于减少排名差异的影响。

单路RRF分数计算公式为：

(10)

系统采用平滑常数 $k=60$ ，该值在RRF原论文中被证明在多种检索任务上表现稳健。 k 值越大，排名靠前的文档优势越不明显，融合结果越倾向于各模块的平均排序； k 值越小，排名靠前的文档优势越明显，融合结果越倾向于各模块的头部结果。

4.4.2 融合流程设计

融合的输入是各路检索模块的Top-10结果、各自的权重以及统一的 k 值，输出为融合后的最终排序。

首先初始化一个空字典用于存放每个文档的累计RRF分数；然后对每一个启用的模块，从其结果列表中按排名顺序取文档，使用该模块的权重除以 $k + \text{rank}$ 计算单路RRF分数，并将这些文档-分数对暂存到临时列表；接着遍历临时列表，按文档名聚合累加分数至字典中，若文档首次出现则先将其分数初始化为0再累加，否则直接累加；所有模块处理完毕后，将字典中的文档按累计RRF分数降序排列，分数相同时按文档名升序排列，最后输出前K个（默认 $K=5$ ）作为融合结果。

4.5 贝叶斯优化算法

多路融合中，给每个模块赋什么样的权重，对最终效果影响明显。人工摸索效率底下，贝叶斯优化则特别适合每次评估都要跑一遍完整检索流程的昂贵优化问题。其基本思路是利用代理模型近似真实的目标函数，通过采集函数指导选择下一组待评

估的权重，避免盲目搜索。

4.5.1 优化问题定义

权重优化问题可形式化为：

(11)

其中为权重向量，为搜索空间，为权重配置w下的F1分数。而目标函数的评估需执行完整的检索测试流程，计算代价较高，因此采用贝叶斯优化进行高效搜索。

4.5.2 贝叶斯优化流程

整个优化过程拆成了四个阶段。第一个阶段，先划定权重的搜索范围：下限设成0.1，是为了避免某个模块被完全忽视，上限5.0则是防止单一模块主导整个融合结果，从而确保三维搜索空间基本上能把合理的权重组合都覆盖到。第二个阶段，定义好目标函数，具体而言就是加载那700个问答对的验证集，使用当前权重配置跑一次RRF融合检索，将算出的F1分数作为结果返回来。第三个阶段，用高斯过程充当代理模型，采集函数选了期望改进（EI），共进行50次迭代。每一轮的具体操作为：先用采集函数挑出下一个要评估的权重点，实测得到F1分数后，再用新数据更新代理模型，同时记录当前最优权重。采集函数的优势在于能在已知好区域里深耕和去陌生区域试探之间找到平衡，这样就不容易掉进局部最优的坑里。50轮跑完之后进入第四个阶段，直接选择使F1分数最高的权重组合作为最优解，同时把完整的优化历史都留下来，便于后面分析收敛过程的稳定性和结果的可靠性。

4.5.3 优化结果分析

经过50次贝叶斯优化迭代，最终得到的最优权重配置为：知识图谱权重为4.785，向量检索权重为0.754，BM25权重为4.182。从最终的权重分配结果可以看出几个值得留意的信息：知识图谱和BM25拿到较高权重，说明在病害诊断这个具体领域里，结构化匹配和精准的关键词匹配起的作用更大；而向量检索的权重偏低，很可能和通用语义模型在专业表述面前理解不够精准有关。权重分布不是均匀的，这也反过来印证了给每路模块单独调权的必要性。再看性能指标的变化，优化后精确率从63.93%升到了72.03%，提升了12.59个百分点；F1分数从72.19%提高到79.65%，增幅7.72%；而召回率和命中率一直稳定在接近100%的水平。这一结果充分表明，贝叶斯优化确实能找到适合这个场景的权重配置，让混合检索的整体性能显著提升，同时未牺牲掉原来就很高的覆盖率和可用性。

6.5 实验结果与分析

总字数：5127

相似文献列表

去除本人文献复制比：0%(0) 去除引用文献复制比：0%(0) 文字复制比：0%(0) 疑似剽窃观点：(0)

原文内容

5 实验结果与分析

实验部分的核心目标，是检验前面设计的三种检索方式——知识图谱检索、向量检索和BM25检索——各自的性能表现，以及通过RRF融合和贝叶斯优化之后，系统整体性能的上限。下文从实验环境、测试数据、流程设计和最终结果几个层面展开。

5.1 实验环境与配置

5.1.1 硬件环境

实验在以下硬件环境下进行：处理器为Intel Core i7-12700H，主频2.30GHz，具备14核20线程；内存为32GB DDR5，频率4800MHz；存储为512GB NVMe SSD，读取速度3500MB/s；显卡为NVIDIA GeForce RTX 3060，显存6GB，用于向量编码加速。

5.1.2 软件环境

实验采用以下软件环境：操作系统为Windows 11专业版64位，Python版本为3.10.11，数据库为用于知识图谱存储的Neo4j 5.12.0 Community Edition和用于向量存储的ChromaDB 0.4.22，深度学习框架为PyTorch 2.1.0与Sentence Transformers 2.2.2，中文分词工具为Jieba 0.42.1，BM25检索实现为rank_bm25 0.2.2。

5.1.3 知识库配置

实验所用的知识库共收录98篇病害知识文档，文本来源包括农业期刊论文、各级植保部门发布的防治手册，以及经过整理的一线专家经验。内容覆盖了小麦条锈病、白粉病、赤霉病、纹枯病、叶锈病、根腐病、全蚀病、黄矮病、丛矮病、霜霉病等四十多种常见病害，总字符规模约245,000字，平均每篇文档大概2500个字符。所有文档都统一存成UTF-8编码的纯文本，便于后续的统一处理和分词。

5.2 测试数据集

5.2.1 数据集构建

测试数据集是人工构建的，由熟悉小麦病害的农业专家和系统开发人员共同标注完成。构建过程大致分了三步。第一步是问题设计，针对每种病害，我们从症状、防治方法、药剂使用、发病条件等几个角度拟出了一批查询问句。设计时注重覆盖面要广、表达方式要多样，并在难度上也做了分层——简单题目占20%，中等难度的占一半，剩下30%是偏难的问题。第二步是标准答案标注，为每个问题指定一到三个标准答案文档。为尽可能减少主观偏差，另请第二位标注者进行交叉验证。第三步汇成最终数据集，一共700个问答对。按类别来看，防治类占35%，症状类占25%，药剂类占20%，其他问题加起来占20%，问题的平均长度大概15个字符。

5.2.2 数据集示例

测试数据集采用JSON格式存储，每个问答对包含以下字段：

表2 问答对字段信息

字段名称	字段描述
Id Question Answer Ground_truth_docs Category Difficulty	问答对唯一标识符 用户查询文本 参考答案描述 标准答案文档列表 问题

字段名称
Id
Question
Answer
Ground_truth_docs
Category
Difficulty
问答对唯一标识符
用户查询文本
参考答案描述
标准答案文档列表
问题类别
问题难度

示例数据如下：
表3 示例数据

字段名称	字段描述
Id Question Answer Ground_truth_docs Category Difficulty	0 小麦纹枯病的防治是什么？ 关于小麦纹枯病的防治，请参考知识库文档。 小麦纹枯病.txt 防治 中等

字段名称
Id
Question
Answer
Ground_truth_docs
Category
Difficulty
0
小麦纹枯病的防治是什么？
关于小麦纹枯病的防治，请参考知识库文档。
小麦纹枯病.txt
防治
中等

5.3 实验流程

5.3.1 实验准备阶段

准备阶段先要完成知识库的整理，把原始文档经过预处理脚本清洗掉页眉页脚、参考文献、作者信息等噪声，得到98篇有效文档。接着跑向量数据库构建脚本，加载m3e-base模型，按500字符块长、50字符重叠的切分策略对所有文档分块并向量化，最终ChromaDB中存入了约372个文档片段。知识图谱方面，则是通过Neo4j Desktop启动图数据库服务，导入预先整理好的病害、症状、病因、药剂等实体及关联数据。最后再加载前面准备好的700个问答对测试集，解析出问题文本和对应的标准答案文档列表，给接下来的检索实验做准备。

5.3.2 单模块检索实验

单模块实验依次测试知识图谱、向量和BM25这三种检索模式各自独立运行时的表现。流程如下：先初始化对应模块，图谱检索需要建立Neo4j连接，向量检索需要加载ChromaDB，BM25则需要提前构建好倒排索引；然后对测试集里700个问题逐个执行检索，每个问题返回前5个文档，同时记录每次检索的耗时；针对每个问题的返回结果，按病害名称口径计算召回率、精确率、F1和命中率；最后把700个问题的各项指标取平均，得到每个模块的综合表现，并将结果分别写入测试历史文件和评估结果JSON文件里。

5.3.3 多模块检索实验

多模块实验考察不同模块组合时的融合效果。为了系统对比，共设计了7种方案：3种单模块、3种双模块组合（图谱加向量、图谱加BM25、向量加BM25），以及1种三模块全组合。在未进行贝叶斯优化之前，融合实验统一给每个模块分配相等的权重1.0，以确保基准对比的公平性。融合策略采用RRF，每个模块独立返回前10个结果，按公式（9）算出单路RRF分数（其中k=60），然后按文档聚合累加，最后按累计分数降序取前5个文档。评价方式与单模块一致，仍为对700个问题的四种指标取平均值。

5.4 实验结果

不同检索方式在召回率、准确率、F1 分数与命中率四项指标上的表现，测试结果如表 4 所示。

表4 不同检索方式的测试结果

检索方案	召回率	准确率	F1分数	命中率
知识图谱	88.86%	41.23%	55.93%	88.86%
向量检索	97.57%	54.02%	65.87%	97.57%
BM25	97.57%	48.45%	61.55%	97.57%
知识图谱+向量检索	100.00%	56.19%	69.24%	100.00%
知识图谱+BM25	99.14%	61.83%	72.88%	99.14%
向量检索+BM25	97.86%	51.68%	64.40%	97.86%
知识图谱+向量检索+BM25	100.00%	70.15%	78.56%	100.00%

检索方案召回率准确率 F1分数命中率

知识图谱 88.86% 41.23% 55.93% 88.86%

向量检索 97.57% 54.02% 65.87% 97.57%

BM25 97.57% 48.45% 61.55% 97.57%

知识图谱+向量检索 100.00% 56.19% 69.24% 100.00%

知识图谱+BM25 99.14% 61.83% 72.88% 99.14%

向量检索+BM25 97.86% 51.68% 64.40% 97.86%

知识图谱+向量检索+BM25 100.00% 70.15% 78.56% 100.00%

5.5 分析与讨论

5.5.1 单模块性能分析

单模块实验的数据比较直观，三种方法各自的优势和短板在指标上反映得很清楚。

知识图谱检索的召回率只有88.86%，精确率41.23%，F1分数55.93%，在三者中综合表现最弱。出现这种情况，主要是图谱检索对实体匹配的依赖程度太高。如果用户提问里没有出现病害名称或者特别规范的症状术语，比如只说了“叶片发黄发枯”而没有提及“条锈病”这类病名，图谱就难以顺着关系边定位到相应实体，从而漏掉不少相关文档。然而，这种检索方式在速度上的优势非常突出——平均每个查询仅耗时4.9毫秒，基本可以忽略延迟。因此，如果将来要部署在一些对实时响应要求严格的场景下，或者仅仅是需要快速确认一个已知病害的防治方案，知识图谱依然很有价值。

向量检索的各项指标是单模块里最好的：召回率97.57%，精确率54.02%，F1分数65.87%。得益于预训练模型对语义的把握，向量检索对同一概念的不同说法、近义词，甚至是表述顺序的变化都有较强的适应力。比如“麦苗上像铁锈一样的粉末”和“条锈病夏孢子堆”这种表达方式差异极大的描述，在向量空间中仍然能被关联。代价则是耗时偏长，平均每次查询需要35.2毫秒，主要消耗在查询文本的向量编码以及在高维空间中与上千个文档片段逐一比对相似度上。虽然ChromaDB做了近似最近邻索引，其计算量仍远超过简单字符串匹配。

BM25检索的召回率同样达到97.57%，但精确率只有48.45%，F1分数61.55%。它擅长的是基于词频和逆文档频率的精确关键词命中，对于包含明确病害名或药名的短查询，能很快锁定相关文档。但其对语义几乎不敏感，容易出现“词匹配但内容不相关”的情况，例如用户问“小麦锈病用什么药”，BM25可能会把含有“锈病”一词但主要讲发病规律的文档也排在前面，从而拉低精确率。好在BM25速度极快，平均每次查询只要0.16毫秒，在三种方式里是最轻量的。

5.5.2 检索模式互补性分析

三种方法从设计思想到实际表现均存在明显差异，把其结合，互补效应得以显现。

在召回率的维度上，知识图谱的88.86%与向量、BM25各自的97.57%之间，有将近9个百分点的缺口。然而，一旦将图谱与另外两种通路结合起来，情况就大为改善：图谱+向量组合的召回率直接提升到100%，图谱+BM25也达到99.14%，三模块融合后同样维持在100%。这充分说明——知识图谱凭借其结构化关联，确实能够检索到其他两条通路落下的一部分病害，三者合在一起才形成了对测试集的完整覆盖。

精确率上的互补同样值得一提。单模块中最高精确率是向量检索的54.02%，但经过融合后，图谱+BM25精确率上升到了61.83%，三模块融合更是达到70.15%，相比最佳单模块提升了超过16个百分点。其内在逻辑在于，不同通路的排序信息起到了交叉验证和去噪的作用。单个模块容易因为自身机制而把某些无关文档排到前面，但在融合过程里，这些文档在其他模块中往往排名很低，最终被挤出前几名。

从检索机制上看，知识图谱依赖的是实体关系网络，走的是逻辑推理路径；向量检索靠的是语义相似度，更侧重于理解文字背后意思；BM25则是基于词汇统计特征，实现的是字面精准匹配。三种机制看待“相关性”的视角完全不同，各自的误检和漏检偏向不一样，这使得融合后的排序比任何单一路径都具有更强的纠错能力和容错性。

5.5.3 融合方案性能分析

三种双模块组合的性能落差比预想的要大。知识图谱+BM25的F1分数达到72.88%，是双模块组合中表现最好的；知识图谱+向量检索为69.24%，也还行；但向量检索+BM25只有64.40%，融合增益明显偏小。根本原因在于向量检索和BM25都是从文档内容出发做匹配，两者返回的结果重叠度本来就比较低，把它们放在一起，组合后新增的互补信息有限。而知识图谱提供的是结构化关联这种完全不同类型的信息，所以与任何一条内容通路组合，都能带来更显著的提升。

三模块融合的结果最能说明问题：召回率达到100%，精确率70.15%，F1分数78.56%，在所有方案中综合性能排第一。融合后的系统既充分利用了语义理解能力，又借助结构化知识缩小了检索范围，加上关键词匹配的保底作用，使得遗漏和误检均得到有效减少。当然，代价也不可忽视，三模块融合的单次查询平均耗时达到27.72秒。这是因为需要依次调用三种通路的检索并等待结果，随后进行RRF融合，每一步均存在积累延迟。在实际部署时，是否需要三路并行，需要看场景对响应时间的具体要求了。

若以单模块中表现最好的向量检索作为基线（F1=65.87%），三模块融合带来的提升相当可观：F1分数提高了12.69个百分点，达到78.56%；精确率提升16.13个百分点，从54.02%升至70.15%；召回率也从97.57%补齐至100%。这些增量主要来自融合过程中对各通路优势的整合，减少了原本单个模块漏掉的相关文档，同时抑制了那些只有字面相关而内容不匹配的噪声结果。

5.5.4 检索策略选择建议

基于上述实验结果与分析，针对不同的使用场景，可以给出几条具体的建议。

若资源吃紧或者需要近乎即时的响应（比如田间手机查询的场合），向量检索单模块是一个靠谱的基准方案，F1分数65.87%能够满足大多数常规提问。如果对结构化查询有刚性需求，比如系统需要根据病害名称精确返回防治知识，知识图谱单模块在速度上有绝对优势。如果追求极致的轻量 and 响应速度，不介意偶尔进来一些噪声结果，BM25单模块凭借0.16毫秒的查询延迟也具备实用价值。

在平衡性能和效率的场景里，知识图谱+BM25的双模块融合是性价比最高的选择。它能够拿到72.88%的F1分数，并且平均耗时只有2.08秒，对用户体验来说基本处于可接受的等待范围。如果更看重语义理解与结构化推理的深度结合，知识图谱+向量检

索也是一个理想选项，适合问题表述比较灵活但专业性较强的咨询场景。

如果场景对诊断准确性和知识覆盖的完整性要求极高，且用户能够接受稍长的处理时间，那么三模块融合显然是最优解。78.56%的F1分数和100%的召回率，意味着系统几乎不会漏掉任何关联的病害知识，且返回结果中的噪声也控制在较低水平，后续大模型推理时可以得到更为充分、可靠的知识上下文。

7. 6 系统实现	总字数：1352
相似文献列表	
去除本人文献复制比：0%(0) 去除引用文献复制比：0%(0) 文字复制比：0%(0) 疑似剽窃观点：(0)	
原文内容	

6 系统实现

本系统融合知识图谱、向量数据库和大语言模型三大核心技术，构建了一个智能化的病害诊断平台。采用Streamlit框架构建交互式Web界面，提供登录认证、病害诊断、检索测试、向量数据库可视化和知识图谱可视化五大功能模块。

6.1 登陆与首页

打开系统进入登录页面，输入正确的账号密码即跳转至首页，可以在首页自由选择进入不同的功能页面。如图2。

图2 登录界面

首页则提供了四个功能页面的跳转按钮和简单介绍，点击按钮即可跳转至对应的功能页面。如图3。

图3 首页界面

6.2 病害诊断

病害诊断模块是系统的核心功能模块，实现了基于混合检索的智能病害诊断能力。如图4。

图4 病害诊断界面

输入症状后，系统会进行诊断，耐心等待不久就会给出诊断结果，如图5。结果出来后会显示在下方，页面底部有导出为pdf按钮，点击即可导出pdf报告，如图6。

图5 病害诊断结果

图6 导出为pdf

6.3 检索测试

检索测试模块可以评估不同检索方式以及多种检索方式混合检索的性能差异。如图7。

图7 检索测试界面

选择好具体配置后即可进行任意一种配置的单独测试，结果如图8。

图8 不同检索方式检索结果

单击完整评估即对所有类型的配置进行统一测试对比，如图9。

图9 完整评估结果

6.4 向量数据库可视化

向量数据库可视化模块，是本系统设计的可视化展示与交互功能模块，能够直观、清晰地呈现向量数据库的存储结构、文档资源以及语义检索能力。如图10。

模块内部进行了清晰的功能分区，各部分各司其职、相互配合。在文档列表区域，可完整浏览已导入知识库的全部原始文档，以及经过分段、切块处理后的文本片段，能够直观查看每条文档片段的具体内容、编号与入库状态，方便随时核对素材入库情况、管理知识库资源。

图10 向量数据库可视化界面

在搜索测试区域，支持手动输入任意自然语言问句或描述文本，系统会将输入内容转化为向量特征，在向量库中进行语义相似度匹配，快速检索并返回语义关联度最高的相似文档片段。不仅可以直观验证向量检索的匹配精度与实际效果，也能直观体现本系统基于向量语义匹配的核心检索优势。如图11。

图11 搜索测试部分

而统计信息区域，提供了向量数据库文档长度信息最直观呈现，包含总文档数、最小长度、最大长度、平均长度等统计指标。通过量化的数据展示，能够清晰掌握向量数据库的文档长度相关信息，为后续的调整提供可靠的数据参考与直观依据。如图12。

图12 统计信息部分

6.5 知识图谱可视化

知识图谱可视化模块展示了知识图谱相关信息，可以查看知识图谱的节点，关系与实体列表等信息。

节点统计部分对核心数据统计，支持按7类节点类型（Disease、Symptom等）分类统计，呈现各类节点数量分布，为知识图谱优化提供数据支撑。如图13。

图13 节点统计部分

关系统计部分可以统计知识图谱中6类核心关联关系（如HAS_SYMPTOM、OCCURS_AT等）的分布，清晰呈现实体间关联逻辑。如图14。

图14 关系统计部分

而在实体列表部分，可以按实体类型筛选，便捷查询、浏览各类实体详细信息，提升知识图谱使用效率。如图15。

图15 实体列表部分

相似文献列表

去除本人文献复制比：3.3%(42) 去除引用文献复制比：3.3%(42) 文字复制比：3.3%(42) 疑似剽窃观点：(0)		
1	预防医学-张诗宇-116120202009-基于GBD数据的慢性肾脏病负担和气象因素的关联性研究 张诗宇 - 《大学生论文联合比对库》 - 2025-05-13	3.3% (42) 是否引证：否

原文内容

7 总结与展望

7.1 总结

针对小麦病害智能诊断这个实际需求，我们设计并实现了一套融合多路检索的诊断系统。整体框架把基于语义的向量检索、基于关键词的BM25检索和基于结构化知识图谱检索三种机制整合到一起，通过倒数排名融合（RRF）算法给出统一排序，并引入贝叶斯优化来为各个模块自动分配最优权重。在技术实现层面，先构建了小麦病害知识图谱，在Neo4j中完成了实体和关系的存储与查询；同时搭建了两条非结构化检索通路，一条靠文本块向量化，另一条依赖倒排索引；另外，还设计了可重复执行的RRF融合流程，以及基于高斯过程的贝叶斯优化策略来搜索权重。在包含700个问答对的测试集上，等权融合的三模块方案召回率达到100%，F1分数为78.56%，经过贝叶斯优化后F1又提升到79.65%，明显优于任何一个单模块的表现。实验数据证明，多路异构检索融合这套思路在小麦病害诊断领域是行得通的，而且各项指标提升幅度都很可观。

7.2 展望

当前的工作虽然取得了阶段性成果，但依然存在不少可以深入打磨的地方。首先，知识图谱的覆盖范围还比较有限，后续应该把小麦的罕见病害、新发病害以及来自植保站、公开数据库的外部知识补充进来，让图谱能覆盖更多边界情况。其次，向量检索目前用的是通用的中文语义模型，面对高度专业的农业术语和病理描述时，语义刻画还不够精准，下一步如果能在小麦病害语料上对模型做领域适配微调，或者引入训练数据更丰富的大规模预训练语言模型，检索质量有望再上一个台阶。融合策略方面，当前RRF只利用了各模块的排名，忽略了原始相似度分数和置信度信息，后续可以探索将原始得分与排名信息联合建模，或者用轻量级的学习方法去拟合融合规则，看看是否能进一步拉开F1的天花板。在系统交互上，现在入口还只有文本描述，未来可以考虑把田间的叶部图像、语音输入也纳入进来，增加连续对话式的诊断功能，降低基层农技人员的手上门槛。另外，知识图谱和文档库目前是静态导入的，建立一套可以接收用户反馈、周期性吸收最新研究成果的自动更新机制，对保持系统长期可用性非常关键。从更长远的角度看，这套多路检索融合加知识图谱的架构并不只适用于小麦，向水稻、玉米等作物进行迁移，借助迁移学习降低重建成本，逐步扩展成一个多作物的病害辅助诊断平台，也是一个值得持续推进的方向。

参考文献

[1] Jigisha J ,Ly J ,Minadakis N , et al. Population genomics and molecular epidemiology of wheat powdery mildew in Europe. [J]. PLoS biology, 2025, 23 (5): e3003097.

[2] Megan L ,Matthew H ,J. R M , et al. Classification of wheat diseases using deep learning networks with field and glasshouse images [J]. Plant Pathology, 2023, 72 (3): 536-547.

[3] Chossegros M ,Hubbard A ,Burt M , et al. Hyperspectral image analysis for classification of multiple infections in wheat. [J]. Plant methods, 2025, 21 (1): 144.

[4] Tegegne G A ,Walle M Y ,Haile B M , et al. Comparative evaluation of CNN architectures for wheat rust diseases classification [J]. Discover Applied Sciences, 2025, 7 (10): 1070-1070.

[5] Liu S ,Dai J ,Huang J , et al. Combining ultralow-altitude drone phenotyping with deep learning analytics to assess resistance and disease dynamics of Fusarium head blight in wheat [J]. The Crop Journal, 2025, 13 (5): 1372-1385.

[6] 张鹏. 春季小麦主要病害及杂草防控技术[J]. 现代农村科技, 2025, (11):57.

[7] Hussain S. 基于深度学习的小麦病害检测方法研究[D]. 合肥: 安徽农业大学, 2023.

[8] 侯俊. 助剂对小麦赤霉病大田飞防效果的影响[J]. 农机市场, 2025, (12):75-77.

[9] 尹利华, 崔艳荣, 曾龙军. 基于改进YOLO v8轻量化小麦病害检测方法研究[J]. 江苏农业科学, 2025, 53(20):279-287.

[10] 郝巧红, 冯庆贺, 江铭凯, 等. 基于改进YOLOV8模型的小麦病害识别[J]. 河南工学院学报, 2025, 33(04):15-18.

[11] 张刚山. 小麦病害防治效果的比较试验: 化学与生物防治方法[J]. 种子科技, 2025, 43(13):32-34.

[12] 李艳莉. 小麦病害早期诊断与综合防控技术[J]. 安徽农学通报, 2025, 31(05):89-92.

[13] 王琦, 韩嘉俊, 焦娇, 等. 小麦赤霉病的综合防治技术及智能监测体系的构建与应用[J]. 粮食问题研究, 2025, (06):35-38.

[14] 康梦倩, 刘旬胜, 刘华丽. 小麦赤霉病防治误区与综合防控策略[J]. 现代农村科技, 2025, (11):59-60.

[15] 刘会锦. 优质小麦种植技术推广和常见病害防治探讨[J]. 粮油与饲料科技, 2025, (13):116-118.

[16] 房利. 无人机遥感技术在小麦病害自动识别中的应用[J]. 农业工程技术, 2025, 45(02):23-24.

[17] 常升龙. 基于深度学习的小麦锈病图像识别和遥感监测研究[D]. 郑州: 河南农业大学, 2024.

[18] 冯子恒. 基于大田图像的小麦病害监测与自动识别技术研究[D]. 郑州: 河南农业大学, 2022.

[19] 纪让军, 李华利, 杜卫东, 等. 小麦白粉病重发原因及综合防治对策[J]. 安徽农学通报, 2026, 32(08):70-73.

[20] 鲍文霞, 胡芳妹, 胡根生, 等. 基于空间深度转换域自适应学习的小麦赤霉病无监督检测方法[J]. 农业机械学报

, 2026, 57(09):270-277.

[21] 卢立明, 王忠晨, 刘刚. 无人机飞防小麦赤霉病的技术探讨[J]. 农业机械, 2026, (03):122-124+132.

[22] 李明轩. 基于改进卷积神经网络的小麦病害检测研究[D]. 长沙: 中南林业科技大学, 2025.

[23] 马超伟, 张浩, 马新明, 等. 基于改进YOLOv8的轻量化小麦病害检测方法[J]. 农业工程学报, 2024, 40(05):187-195.

[24] 蒋玲. 基于边缘计算的小麦病害检测方法研究与实现[D]. 扬州: 扬州大学, 2023.

[25] 廖子涵. 基于多特征融合的小麦病害识别技术研究[D]. 哈尔滨: 哈尔滨理工大学, 2024.

致谢

由衷感谢所有给予我帮助与支持的师长、亲友与同窗。

首先诚挚感谢指导老师司海平教授，从论文选题、框架构思到实验研究与定稿修改，导师全程悉心指点。其严谨务实的治学态度与扎实深厚的学术功底，让我收获颇丰，也助我顺利完成学业研究。

同时感谢各科授课老师传授专业知识，感谢实验室同窗相伴研学、互帮互助，一同探讨学术难题，共同成长进步。也感谢参与论文评审的各位专家，提出宝贵修改意见，完善论文内容。

最后深切感恩家人的默默陪伴与鼎力支持，感谢挚友一路鼓励相伴，成为我求学路上最坚实的力量。此次论文撰写是大学学业的总结，亦是全新征程的开端，往后我必将不忘初心，砥砺前行。

指 标
疑似剽窃文字表述
1. 由衷感谢所有给予我帮助与支持的师长、亲友与同窗。 首先诚挚感谢指导老师司海平教授，

说明：1. 总文字复制比：被检测论文总重合字数在总字数中所占的比例

2. 去除引用文献复制比：去除系统识别为引用的文献后，计算出来的重合字数在总字数中所占的比例

3. 去除本人文献复制比：去除作者本人文献后，计算出来的重合字数在总字数中所占的比例

4. 单篇最大文字复制比：被检测文献与所有相似文献比对后，重合字数占总字数的比例最大的那一篇文献的文字复制比

5. 复制比：按照“四舍五入”规则，保留1位小数

6. 指标是由系统根据《学术论文不端行为的界定标准》自动生成的

7. 红色文字表示文字复制部分；绿色文字表示引用部分(包括系统自动识别为引用的部分)；棕灰色文字表示系统依据作者姓名识别的本人其他文献部分

8. 本报告单仅对您所选择的比对时间范围、资源范围内的检测结果负责



 amlc@cnki.net

 <https://check.cnki.net/>